

GradCell K=0 实验报告：偏好条件化电芯设计初始化器

实验标识： K=0 initializer, SPMe, 1C/5C/6C, 高倍率线性约束版本

模型随机种子： 7

参考数据随机种子： 101

报告日期： 2026-09-05

摘要


本实验验证 GradCell 的第一项核心能力：是否能够训练一个偏好条件化初始化器，把用户给定的能量—高倍率性能偏好 $\lambda \in [0, 1]$ 直接映射为可行电芯设计。K=0 表示模型只使用神经网络产生初始设计，不执行后续的梯度型 refiner 更新。网络输出五维有界 latent，经硬可行解码器转换为电极与隔膜结构参数，再分别送入 PyBaMM SPMe 的 1C、5C 和 6C 放电仿真。训练目标同时最大化 1C 比能量和最差高倍率能量保持率 $\min(R_5, R_6)$ ，并通过线性罚项要求 $R_5 \geq 0.50$ 、 $R_6 \geq 0.44$ 。梯度由电芯目标穿过可微指标、PyBaMM 前向灵敏度、自定义向量—雅可比、结构解码器和神经网络完成端到端反传。

在 21 个标准偏好点的 hard-cutoff SPMe 评价中，仿真成功率和约束满足率均为 100%，全部候选设计优于标称设计；相对有限参考 Pareto 集的平均 scalarized regret 为 0.00631，中位数为 0.00124。20 个离网格中点同样全部仿真成功、满足约束并优于标称设计，能量随 λ 单调增加、6C 保持率单调下降，说明模型确实学习到了偏好到设计的连续映射，而不是对 21 个评价点输出同一个方案。不过， $\lambda = 0.175 \rightarrow 0.225$ 存在显著 latent 跳变，且高能量端 regret 较大；前三个 latent 长期接近上边界。这表明当前模型在 Pareto 膝点附近可能发生设计分支切换，设计自由度也存在部分饱和。现有结果不支持“明显过拟合”的判断，但由于只有一个模型种子、训练与评价均使用 SPMe、训练偏好样本未逐项留档，因此还不能证明跨种子、跨物理模型或严格 held-out 偏好泛化。

1. 实验目的

GradCell 的目标不是单点回归某个固定性能值，而是学习一个能够响应多目标偏好的设计生成器。K=0 实验回答的问题是：不给模型任何迭代优化步骤，只提供偏好 λ ，神经网络能否一次性提出满足物理结构约束和高倍率约束、并接近参考 Pareto 前沿的电芯设计。

这里 $\lambda = 1$ 更偏重 1C 比能量， $\lambda = 0$ 更偏重高倍率保持率。理想模型不应为所有 λ 输出同一设计，而应随着偏好变化生成一族有序、可行且性能互有取舍的设计。K=0 同时也是后续 K=3 refiner 的起点：只有先证明 initializer 学会了可靠映射，才能判断迭代细化带来的增益是否真实。



2. 模型框架

2.1 偏好编码与初始化网络

模型唯一的任务输入是标量偏好 λ 。FourierPreferenceEncoder 将它与 1 至 8 阶的正弦、余弦特征拼接，形成 $1 + 2 \times 8 = 17$ 维特征：

$$x(\lambda) = [\lambda, \sin(2\pi\lambda), \cos(2\pi\lambda), \dots, \sin(16\pi\lambda), \cos(16\pi\lambda)].$$

该特征经过两层带 SiLU 与 LayerNorm 的全连接网络，得到 128 维任务嵌入。DesignInitializer 随后使用宽度为 256 的输入层和四个残差块生成五维向量。输出层初始化为零，并通过

$$u_0 = 2 \tanh(\Delta u)$$

把每个 latent 分量限制在 $(-2, 2)$ 内。零初始化意味着训练开始时所有偏好均对应标称 latent $u = 0$ ，之后网络才逐步学习偏好相关的设计差异。

2.2 硬可行设计解码

五维 latent 不直接作为 PyBaMM 参数，而是由 DesignSpace 确定性地解码为结构设计。前三维分别控制正极孔隙率、负极孔隙率和隔膜孔隙率；第四维控制正极活性材料体积分数；第五维控制 N/P 比。负极活性材料体积分数由容量平衡关系推导，而不是独立预测。当前阶段固定 Chen2020 材料体系，正负极固相扩散系数乘子均为 1，因此模型优化的是结构而非材料动力学参数。

设计量	来源	范围或约束	含义
ε_p	u_1 经 sigmoid	0.20–0.42	正极孔隙率
ε_n	u_2 经 sigmoid	0.20–0.42	负极孔隙率
ε_s	u_3 经 sigmoid	0.35–0.60	隔膜孔隙率
ϕ_p	u_4 经动态上界映射	同时满足孔隙、非活性相与容量平衡	正极活性材料体积分数
N/P	u_5 经 sigmoid	1.02–1.25	负极容量与正极容量之比
ϕ_n	容量平衡公式推导	与 ϕ_p 、N/P 联动	负极活性材料体积分数

这种解码方式把孔隙率边界、最小非活性材料比例和电极容量平衡直接写入参数化过程。网络不能生成违反这些硬结构约束的设计，因此无需依赖额外 Loss 去“学会”基本可行性。

2.3 SPMc 物理计算链

每个设计分别在 1C、5C 和 6C 下执行 PyBaMM SPMc 放电仿真，对应固定计算时域 3600 s、720 s 和 600 s。标称容量使用 chen2020_scaled 公式，并乘以参考数据校准得到的 1.2589438522。仿真输入张量包含正负极与隔膜孔隙率、正负极活性材料体积分数、两个固定为 1 的扩散系数乘子以及由标称容量和 C-rate 得到的电流。

软截止门函数定义为

$$g(V) = \sigma\left(\frac{V - 2.5}{0.02}\right),$$

并用于计算可微的放电能量。某一倍率 C 下的比能量可写成

$$E_C = \frac{1}{3600m} \int I_C V_C(t) g(V_C(t)) dt,$$

其中 m 是解码器计算的电堆质量。训练指标为

$$E = E_{1C}, \quad R_5 = \frac{E_{5C}}{E_{1C}}, \quad R_6 = \frac{E_{6C}}{E_{1C}}, \quad R_{\text{high}} = \min(R_5, R_6).$$

这里使用的是高倍率**能量保持率**，不是容量保持率。实验数据中通常有 $R_6 < R_5$ ，因此最差高倍率目标多数由 6C 决定。

3. 实验数据与参考 Pareto 前沿

3.1 数据制造流程

参考数据不是实验室实测数据，而是在五维可行设计空间内随机采样 5000 个结构方案，并用 PyBaMM SPMe 进行 hard-cutoff 的 1C、3C、5C 和 6C 放电计算得到。K=0 当前使用的主要字段为 1C、5C 和 6C 能量。参考数据文件为 `data/gradcell_reference_spme_1c5c6c_5000_s101.npz`，采样种子为 101。

5000 个样本显示出明显的双簇或强非均匀分布。5C 能量保持率范围为 0.02783–0.52306，中位数仅为 0.14935，而第 75 百分位跃升至 0.51276；6C 范围为 0.02540–0.46146，中位数为 0.08660，第 90 百分位达到 0.45301。 R_5 与 R_6 的相关系数为 0.7333。早期尝试的 $R_5 \geq 0.55$ 、 $R_6 \geq 0.45$ 中，5C 阈值超过整个样本集最大值，因此没有任何可行样本。最终阈值调整为

$$R_5 \geq 0.50, \quad R_6 \geq 0.44,$$

使约束落在已观测高倍率性能区域内，同时保留足够的设计取舍空间。

3.2 参考 Pareto 集

在满足上述约束的样本中，按“最大化 1C 比能量”和“最大化 $\min(R_5, R_6)$ ”进行非支配筛选，得到 25 个互不相同的 Pareto 设计。其统计范围如下。

指标	参考 Pareto 范围
1C 比能量	112.9399–162.4365 Wh/kg
5C 能量保持率	0.515175–0.523060
6C 能量保持率	0.448766–0.461458
两目标相关系数	-0.451304

负相关说明能量与高倍率保持率之间确实存在取舍，但前沿是有限的 5000 次随机搜索结果，而不是真实全局 Pareto 前沿。后续所谓 oracle 只是针对该有限参考集，在每个 λ 下选择 scalarized loss 最小的样本。

4. Loss、梯度与训练流程

4.1 多目标标量化

首先使用参考前沿中的 ideal 与 nadir 对两个目标归一化：

$$d_E = \frac{E_{\text{ideal}} - E}{E_{\text{ideal}} - E_{\text{nadir}}}, \quad d_R = \frac{R_{\text{ideal}} - \min(R_5, R_6)}{R_{\text{ideal}} - R_{\text{nadir}}}.$$

偏好权重为 $w = [\lambda, 1 - \lambda]$ 。Smooth augmented Tchebycheff Loss 为

$$L_{\text{tch}} = au \log \sum_j \exp\left(\frac{w_j d_j}{\tau}\right) + \rho \sum_j w_j d_j,$$

其中 $\tau = 0.05$ 、 $\rho = 0.05$ 。它近似最小化两个加权目标距离中的较大者，并用较小的加和项改善 Pareto 解的区分度。

高倍率约束采用线性 ReLU 罚项：

$$L_{\text{constraint}} = 5 [\max(0, 0.50 - R_5) + \max(0, 0.44 - R_6)].$$

最终单样本目标为

$$L = L_{\text{tch}} + L_{\text{constraint}}.$$

线性罚项在违反约束时保持非零的一阶梯度，比此前平方罚项更能阻止设计停留在边界外。若物理仿真失败，代码使用 $100 + 0.1\|u\|_2^2/5$ 作为失败损失；若整个 batch 均失败，训练会直接中止，避免把失败区域误当作可学习的正常目标。

4.2 端到端反传

K=0 的 batch Loss 是 $L(u_0)$ 的均值。执行 `loss.backward()` 后，梯度路径为

$L \rightarrow (E, R_5, R_6) \rightarrow V_{1C,5C,6C}(t) \rightarrow \text{SPMe参数} \rightarrow \text{结构设计} \rightarrow u_0 \rightarrow \text{initializer与任务编码器参数}.$

PyBaMM 在 CPU 上完成 SPMe 正向求解和参数前向灵敏度计算；自定义 PyTorch 层在反向阶段计算向量—雅可比 $J^T v$ 。因此 Loss 的确在进行梯度下降，而且物理仿真位于训练计算图中，不是离线标签或训练后的独立评价器。

4.3 训练设置

本次 K=0 使用 1000 个训练 step、batch size 8、AdamW 优化器、学习率 3×10^{-4} 、weight decay 10^{-5} ，并将梯度范数裁剪到 1.0。偏好采样并非只取固定网格：50% 来自均匀分布，25% 来自 Beta(0.5, 2) 以加强高倍率端，25% 来自 Beta(2, 0.5) 以加强高能量端。每 25 step 在 11 个固定偏好点上计算验证 Loss 并保存最优模型。1000 step 的服务器训练耗时约 19654 s，即 5.46 h，主要开销是 CPU 上每个 batch 的三组 SPMe 仿真及灵敏度计算，而不是小型神经网络本身。

训练期间每个 step 采样 8 个 λ ，因此一轮 1000-step 训练处理了 8000 个“偏好实例”。这些不是 8000 个预先保存的监督样本，而是运行时动态产生的任务输入；同一个或相近的 λ 可以在不同 step 再次出现，其设计会随着网络权重更新而变化。每个偏好需要执行 1C、5C、6C 三次物理求解，因此主训练阶段理论上执行

$$1000 \times 8 \times 3 = 24,000$$

次 SPMe 前向求解。若完整训练每 25 step 在 11 个偏好上验证一次，则 40 次验证额外产生 $40 \times 11 \times 3 = 1320$ 次求解；训练开始前 $\lambda = 0, 0.5, 1$ 的 preflight 再产生 9 次。因此在没有早停、重试和失败额外求解的理想计数下，总计约 25,329 次 SPMe 求解。这个数值是根据配置推导的工作量，不是从求解器日志直接统计的实测调用数；若需要精确数目，应在物理 backend 中增加调用计数器。

4.4 数据类型与张量形状

本轮网络使用 PyTorch float64，以匹配物理求解和灵敏度计算所需的数值精度。设 batch size 为 $B = 8$ ，主要张量形状如下。PyBaMM 返回的电压轨迹长度取决于 backend 的统一输出网格，本文未获得服务器数组形状，因此以 T_C 表示对应倍率的时间点数。

数据	dtype	形状	来源与作用
preference λ	float64	$[B]$	在线随机采样的多目标偏好
Fourier 特征	float64	$[B, 17]$	λ 与 8 组 sin/cos
task embedding	float64	$[B, 128]$	偏好编码器输出
latent u_0	float64	$[B, 5]$	initializer 输出
解码物理输入	float64	$[B, 8]$	5 个结构量、推导量、固定扩散乘子和电流
1C/5C/6C 电压	float64	$[B, T_1]$ 、 $[B, T_5]$ 、 $[B, T_6]$	SPMe 输出
status	int64/bool	$[B]$	三倍率仿真是否均成功且有限
E, R_5, R_6, L	float64	各为 $[B]$	指标与单样本 Loss
batch Loss	float64	标量	单样本 Loss 的均值

5000 个参考样本与 $K=0$ 在线训练任务是两套不同数据流。前者是离线随机设计—仿真数据，用于确定可行区、构建有限参考 Pareto 集、提供 ideal/nadir 和评价 oracle；后者不读取 5000 个设计作为标签，而是由当前网络在线提出设计并直接通过 SPMc 计算 Loss。因而不能把 $K=0$ 简化描述为“用 5000 条数据训练 0.58M 参数的监督网络”。更准确的描述是：5000 条离线数据负责标定和评价，约 8000 个动态偏好实例及约 25,329 次 SPMc 求解负责单次 $K=0$ 端到端训练与验证。

5. 实验结果

5.0 模型规模与计算量

当前完整 GradCell 对象包含任务编码器、initializer 和 refiner，共有 686,091 个神经网络参数。不过 $K=0$ 前向过程中 num_steps=0，refiner 不参与结果计算，因而本实验实际被 Loss 约束并获得有效梯度的是任务编码器与 initializer，共 580,485 个参数。其中 Fourier 偏好编码器有 19,328 个参数，initializer 有 561,157 个参数；未被 $K=0$ 使用的 refiner 有 105,606 个参数。按 float64 计算， $K=0$ 权重本身约占 4.64 MB；若计入梯度和 AdamW 的一阶、二阶状态，参数相关存储约为 18.6 MB。训练耗时并非由网络规模主导，而是由每个 batch 对 1C、5C、6C 三套 SPMc 方程进行求解和灵敏度计算所主导。

5.1 标准偏好网格评价

在 $\lambda = 0, 0.05, \dots, 1.0$ 共 21 个偏好点上，使用 hard-cutoff SPMc 重新评价 $K=0$ 候选方案，得到如下结果。

指标	K=0 线性约束结果
SPMc 仿真成功率	1.0000
5C/6C 约束满足率	1.0000
平均 scalarized regret	0.006311
中位 scalarized regret	0.001241
优于标称设计的比例	1.0000
唯一 latent 设计数	21/21

指标	K=0 线性约束结果
latent 两端距离	5.32596
1C 比能量范围	113.8299–159.7662 Wh/kg
5C 能量保持率范围	0.515186–0.522984
6C 能量保持率范围	0.442010–0.461338

这些数字表明模型没有发生偏好坍缩：21 个偏好点产生了 21 个不同设计，且能覆盖从高倍率优先到高能量优先的性能区间。最高预测能量低于有限参考前沿的 162.4365 Wh/kg，但换来了所有偏好点均满足高倍率约束。Regret 的量级较小，说明大多数候选接近当前参考集在相同偏好下的最佳标量化结果。

5.2 线性约束相对平方约束的改进

此前平方约束版本的约束满足率为 20/21，即 0.95238；平均 regret 为 0.007058，中位 regret 为 0.002848。改为线性约束后，约束满足率提高到 21/21，平均 regret 降低约 10.6%，中位 regret 降低约 56.4%，同时仍保持所有候选优于标称设计。代价是候选最大能量由约 160.738 降至 159.766 Wh/kg，下降不足 1 Wh/kg。这个取舍是合理的，因为旧版本的最高能量端曾把 R_6 降到约 0.4215，明显违反 0.44 的约束。

5.3 离网格偏好插值

为避免只在标准评价网格上验证，进一步使用 0.025, 0.075, ..., 0.975 共 20 个中点进行测试。这些数值不在标准 0.05 网格上，但由于历史训练过程中随机抽取的精确 λ 未被记录，本测试只能称为离网格插值，不能称为严格从未见过的 held-out- λ 测试。

指标	离网格中点结果
SPMe 仿真成功率	1.0000
约束满足率	1.0000
优于标称设计比例	1.0000
平均 / 中位 / 最大 regret	0.005442 / 0.002290 / 0.032285
唯一 latent 设计数	20/20
能量单调性违反次数	0
6C 保持率单调性违反次数	0
平均 / 中位相邻 latent 距离	0.35935 / 0.17362
最大相邻 latent 距离	3.68338

离网格能量范围为 113.8314–159.7681 Wh/kg， R_5 范围为 0.515185–0.522983， R_6 范围为 0.441905–0.461338。能量随能量偏好增强而单调上升，6C 保持率则单调下降，符合多目标取舍的物理与优化语义。这是模型学习到条件映射的直接证据。

5.4 原始参考样本的高倍率性能分布

原始 5000 个 SPM_e 样本的分位数进一步说明，设计空间不是一个均匀、平滑的简单区域。5C 性能在第 50 至第 75 百分位之间由 0.14935 快速上升到 0.51276；6C 性能则在第 75 至第 90 百分位之间由 0.15313 上升到

0.45301。也就是说，相当一部分随机设计在高倍率下很早触发电压截止，而另一批设计集中在较窄的高性能平台上。这种分布会使 Pareto 前沿和神经网络映射出现明显膝点。

分位数	$R_5 = E_{5C}/E_{1C}$	$R_6 = E_{6C}/E_{1C}$	$\min(R_5, R_6)$
P00	0.027826	0.025402	0.025402
P01	0.034065	0.030409	0.030409
P05	0.044593	0.038279	0.038279
P10	0.052295	0.043607	0.043607
P25	0.076452	0.058590	0.058590
P50	0.149352	0.086599	0.086599
P75	0.512758	0.153132	0.153132
P90	0.517171	0.453008	0.453008
P95	0.518865	0.455777	0.455777
P99	0.520911	0.458648	0.458648
P100	0.523060	0.461458	0.461458

不同候选阈值下的联合可行样本数量如下。该表来自完整 5000 样本而不是 Pareto 子集，可用于解释为何最终约束需要依据真实分布设置。P50 阈值仍保留 2355 个联合可行样本，而最初尝试的 $R_5 \geq 0.55$ 已超过观测最大值 0.52306，因此可行数必然为零。当前正式阈值 0.50/0.44 不对应表中同一分位数组合，而是针对高性能平台设置的工程阈值；仍应在完整数据上另外报告其确切联合可行数。

阈值来源	$R_{5,\min}$	$R_{6,\min}$	联合可行数	比例
P10	0.052295	0.043607	4488	89.76%
P20	0.068223	0.053734	3969	79.38%
P25	0.076452	0.058590	3696	73.92%
P30	0.084284	0.062840	3428	68.56%
P40	0.106072	0.072853	2905	58.10%
P50	0.149352	0.086599	2355	47.10%

5.5 标准网格设计多样性

21 个标准偏好点对应的各维 latent 标准差为

$[1.3175 \times 10^{-4}, 1.5175 \times 10^{-4}, 1.0428 \times 10^{-4}, 1.2813, 1.5634].$

前三维标准差比后两维低四个数量级，说明正极孔隙率、负极孔隙率和隔膜孔隙率在本轮最优设计族中几乎不随偏好改变；主要取舍由正极活性材料比例相关变量和 N/P 比控制。标准网格两端的 latent 欧氏距离为 5.32596，且 21 个向量经当前精度去重后全部唯一，因此整体上没有输出坍塌。另一方面，“唯一”并不等于每一维都有效：现有五维设计空间中只有约两维承担了大部分偏好变化。

5.6 离网格局部变化明细

离网格相邻偏好之间最大的 latent 变化集中在 $\lambda = 0.175 \rightarrow 0.225$ 。下表列出了已从服务器结果中提取的八个最大相邻跳变。正的 ΔE 表示比能量增加，负的 ΔR 表示高倍率保持率下降。

偏好区间	latent 距离	ΔE (Wh/kg)	ΔR_5	ΔR_6
0.175→0.225	3.683383	+9.654179	-0.00135420	-0.00176339
0.225→0.275	0.406424	+4.950264	-0.00073567	-0.00095821
0.125→0.175	0.381201	+0.176792	-0.00004423	-0.00004888
0.325→0.375	0.303991	+4.460502	-0.00071456	-0.00098316
0.425→0.475	0.298043	+4.523567	-0.00077364	-0.00114045
0.275→0.325	0.233155	+3.207254	-0.00049479	-0.00066069
0.475→0.525	0.214625	+3.189917	-0.00056994	-0.00089300
0.775→0.825	0.198680	+2.023831	-0.00043317	-0.00128037

最大跳变附近的 latent 原始值显示，前三维已经非常接近 +2；第五维则在 $\lambda = 0.175 \rightarrow 0.225$ 时由 1.60879 跳到 -1.98996，第四维也开始明显变化。这正是总体最大相邻距离达到中位相邻距离 21.21 倍的原因。

λ	u_1	u_2	u_3	u_4	u_5
0.075	1.999868	1.999885	1.999906	-1.995737	1.991981
0.125	1.999762	1.999784	1.999829	-1.993426	1.989970
0.175	1.999993	1.999993	1.999995	-1.989399	1.608790
0.225	1.999989	1.999987	1.999991	-1.204328	-1.989955
0.275	1.999967	1.999957	1.999971	-0.797909	-1.992053
0.325	1.999962	1.999948	1.999967	-0.564759	-1.993495

5.7 离网格高 regret 点

已提取的最大 regret 点见下表。高能量端 $\lambda \geq 0.825$ 连续出现较高 regret，说明该端的逼近误差具有系统性； $\lambda = 0.175$ 的高 regret 则与局部分支跳变相重合。

λ	regret	比能量 (Wh/kg)	R_5	R_6
0.975	0.032285	159.768079	0.51518488	0.44190464
0.175	0.024948	114.019781	0.52293730	0.46128653
0.925	0.024360	159.657806	0.51520993	0.44732146
0.875	0.019559	159.247976	0.51530104	0.44813562
0.825	0.013850	158.048833	0.51556577	0.44929085

λ	regret	比能量 (Wh/kg)	R_5	R_6
0.225	0.012148	123.673960	0.52158310	0.45952314
0.275	0.010026	128.624224	0.52084743	0.45856493
0.325	0.007761	131.831478	0.52035264	0.45790423

5.8 模型、参考前沿和有限 oracle 的覆盖对比

K=0 的能量范围覆盖参考前沿范围的主要部分，但高能量上限低约 2.67 Wh/kg。K=0 的最低 R_6 为 0.44201，低于可行参考 Pareto 集报告的 0.44877，却仍高于训练约束 0.44；这说明模型在偏好极端处找到的是“满足约束但不属于当前有限可行前沿样本范围”的连续设计。参考前沿由 25 个非支配样本组成，而在 21 个离散偏好下，有限 oracle 只选择了 9 个唯一设计。K=0 则输出 21 个唯一设计，这意味着连续网络对稀疏参考点之间进行了插值，而不是逐点复制 oracle。

对象	唯一设计数	比能量范围 (Wh/kg)	R_5 范围	R_6 范围
K=0, 标准 21 点	21	113.8299–159.7662	0.515186–0.522984	0.442010–0.461338
K=0, 离网格 20 点	20	113.8314–159.7681	0.515185–0.522983	0.441905–0.461338
有限 oracle, 21 点	9	112.9399–162.4365	0.515175–0.523060	0.448766–0.461458
完整参考 Pareto 集	25	112.9399–162.4365	0.515175–0.523060	0.448766–0.461458

6. 数据分析与讨论

6.1 K=0 是否真正学到了映射

综合标准网格和离网格结果，答案是“在当前 SPM_e 设计域内，已经学到了有意义的插值映射”。关键证据不是训练 Loss 本身，而是离网格的 20 个偏好产生 20 个不同设计，输出性能具有正确的单调次序，全部通过 hard-cutoff SPM_e，且都优于标称设计。若网络只是记忆少数评价点或完全忽略 λ ，不会同时呈现这些性质。

但是，映射不是处处平滑。最大跳变发生在 $\lambda = 0.175 \rightarrow 0.225$ ：latent 距离为 3.68338，1C 比能量增加 9.65418 Wh/kg，而 R_5 和 R_6 分别只下降 0.001354 和 0.001763。观察 latent 可见，主要变化来自第四、第五维，即正极活性材料比例相关自由度与 N/P 比；前三维则几乎固定在 +2 的 latent 上界。这个现象有两种并存的解释。其一，真实参考前沿在该区域存在 Pareto 膝点或不同设计分支，有限参考 oracle 在 21 个偏好上也只有 9 个唯一设计，支持“分支切换”解释。其二，Fourier 网络可能用较陡的函数近似这一切换，使 latent 局部连续性不足。现有数据不能把两者完全区分。

6.2 性能不足集中在哪里

离网格最大 regret 出现在 $\lambda = 0.975$ ，为 0.032285； $\lambda = 0.925$ 和 0.875 的 regret 也相对较高，说明纯高能量端附近仍有局部欠拟合。另一个高 regret 点是 $\lambda = 0.175$ ，恰好位于大跳变之前，表明 Pareto 膝点附近也较难学习。平均和中位 regret 的差距较大，说明整体表现良好，但少数端点与转折点拉高了均值。下一轮提高精度时，应优先对 [0.15, 0.25] 和 [0.85, 1.0] 加密偏好采样，而不是无差别增加全部训练步数。

前三个 latent 的标准差仅约 10^{-4} ，后两维标准差约为 1.28 和 1.56。结合前三维接近 +2 上界的观测，当前 Pareto 族实际上主要依赖后两个自由度。这可能意味着当前 SPM_e 与目标更偏好孔隙率边界，也可能意味着结构范围、质量模型或目标定义把最优解推到了边界。模型虽然输出五维，但有效设计流形接近二维；这既降低了学习难度，也提示现有设计空间尚不足以全面证明 GradCell 对复杂高维设计的能力。

6.3 是否过拟合

当前没有出现典型的偏好过拟合证据。离网格指标与标准网格接近：离网格平均 regret 0.00544，并未比标准网格的 0.00631 恶化；性能单调性保持完整，设计也没有坍缩。因此不能依据现有结果把 $K=0$ 判定为过拟合。

不过，“没有证据表明过拟合”不等于“已经证明泛化”。训练和评价使用相同 SPM_e 模型、相同参数体系与同一可行设计域；只运行了模型种子 7；有限参考前沿也来自同一个 5000 样本数据集。此外，随机训练入没有被完整记录，离网格点可能曾被非常接近地采样过。严格结论应限定为： $K=0$ 在同分布的 SPM_e 偏好插值任务上表现良好，尚未验证跨随机种子、跨设计域、跨仿真精度和跨真实电芯的泛化。

6.4 Regret 的解释边界

个别候选可能出现负 regret。这不表示模型优于真实全局最优，而表示它优于 5000 个随机参考样本构成的有限 oracle。神经网络通过连续梯度优化可以落在参考采样点之间，因此出现小幅负值是合理的，也进一步说明参考 Pareto 集应被视为评价基线而非数学意义上的精确前沿。

7. 结论

$K=0$ 已经完成了一个可信的基线闭环：偏好入神经网络生成有界 latent，硬可行解码器得到电芯结构，1C/5C/6C SPM_e 产生性能，Smooth Tchebycheff 与线性高倍率约束给出 Loss，梯度再穿过物理层更新网络。标准网格评价实现 100% 仿真成功、100% 约束满足、100% 优于标称设计，且平均 regret 为 0.00631；离网格插值保持相同的可行性和单调取舍。因此， $K=0$ 已证明 GradCell initializer 能在当前受限设计域和 SPM_e 模型内学习偏好到设计的映射。

这项成果尚不能被表述为“得到真实电芯的全局最优设计”。下一步最重要的验证不是简单增加训练轮数，而是进行至少 3–5 个模型种子的重复实验、记录训练偏好并划分真正的 held-out 偏好区间、在 Pareto 膝点与高能量端定向采样、用 PyBaMM DFN 复核候选排序与约束，并检查边界设计在更宽参数域和制造约束下是否仍合理。完成这些验证后， $K=0$ 才能作为 $K=3$ refiner 增益比较和真实设计推广的稳固基线。

8. 复现实验与代码对应

$K=0$ 训练入口为 `scripts/run_gradcell_exploration.py --stage train-k0`，核心模型位于 `src/gradcell/models/gradcell.py`。偏好编码、初始化器、可行解码、Loss、训练器和离网格评价分别位于 `src/gradcell/models/task_encoder.py`、`src/gradcell/models/initializer.py`、`src/gradcell/design/feasible_decoder.py`、`src/gradcell/losses/scalarization.py`、`src/gradcell/training/trainer.py` 和 `scripts/evaluate_unseen_preferences.py`。

本次设置的典型复现命令如下：

```
python scripts/run_gradcell_exploration.py \
  --stage train-k0 \
  --reference-samples 5000 \
  --reference-seed 101 \
  --training-steps 1000 \
  --batch-size 8 \
  --preference-points 21 \
  --model-seed 7 \
  --output-root results/gradcell_exploration_linear_constraint

python scripts/run_gradcell_exploration.py \
```

```
--stage evaluate-k0 \  
--reference-samples 5000 \  
--reference-seed 101 \  
--preference-points 21 \  
--model-seed 7 \  
--output-root results/gradcell_exploration_linear_constraint  
  
python scripts/run_gradcell_exploration.py \  
--stage evaluate-k0-unseen \  
--reference-samples 5000 \  
--reference-seed 101 \  
--preference-points 21 \  
--model-seed 7 \  
--output-root results/gradcell_exploration_linear_constraint
```

报告中的实验数值来自本轮服务器输出及其 `candidates.npz`、评价摘要和参考前沿元数据。由于本地仓库未包含完整服务器运行目录，本文没有补造未提供的逐 step Loss、逐偏好标准网格明细或训练/验证曲线。

9. 尚缺数据、获取方法与填写位置

当前报告已经覆盖参考样本分布、参考前沿、标准与离网格总体指标、设计多样性、主要局部跳变和高 regret 点，但还缺少完整的训练轨迹、21 个标准点逐点结果、20 个离网格点完整结果、正式阈值下的原始样本可行数、物理失败统计、跨种子重复和 DFN 外部复核。这些缺项决定了报告目前适合作为单次 SPMe 方法验证，而尚不足以作为完整统计实验结论。

缺失数据	为什么需要	应写入报告的位置
每个 step 的 train/final/validation Loss	判断收敛、振荡、最佳 checkpoint 和 train-validation gap	5.9 训练轨迹
21 个标准入的逐点设计与性能	判断局部错误、端点误差和单调性	5.1 后附表
20 个离网格点的完整逐点表	目前仅有八个最大 regret 点	5.3 后附表
0.50/0.44 下的联合可行样本数	定量说明约束严格程度	5.4
5000 样本有效率和各倍率失败率	评估参考数据是否有选择偏差	3.1
3-5 个训练种子均值与标准差	判断结论是否依赖 seed 7	新增 5.9
DFN 复核误差和排序一致性	判断是否只适配 SPMe	新增 5.10
真正 held-out 偏好区间	区分插值能力与训练分布外泛化	新增 5.11

9.1 导出完整训练轨迹

服务器运行目录内应有 `training_steps.jsonl`。先定位文件：

```
find results/gradcell_exploration_linear_constraint -name 'training_steps*.jsonl'  
-print
```

然后将实际路径替换到下面脚本中。脚本会输出训练记录数、首末 Loss、最小训练 Loss、最佳验证 Loss 及其 step、最后 100 step 的均值和标准差，并生成可直接放入报告的 CSV。

```
python - <<'PY'
import json
from pathlib import Path
import numpy as np

path = Path("请替换为实际run目录/training_steps.jsonl")
rows = [json.loads(line) for line in path.read_text().splitlines() if
line.strip()]
train = np.array([r["train_loss"] for r in rows], dtype=float)
val_rows = [r for r in rows if "validation_loss" in r]
val = np.array([r["validation_loss"] for r in val_rows], dtype=float)
val_steps = np.array([r["step"] for r in val_rows], dtype=int)

print("training records:", len(rows))
print("first/last train loss:", train[0], train[-1])
print("minimum train loss:", train.min(), "at step", rows[int(train.argmin())]
["step"])
print("last-100 mean/std:", train[-100:].mean(), train[-100:].std(ddof=1))
if len(val):
    i = int(val.argmin())
    print("best validation loss:", val[i], "at step", val_steps[i])
    print("last validation loss:", val[-1])

with Path("k0_training_curve.csv").open("w", encoding="utf-8") as f:
    f.write("step,train_loss,final_loss,validation_loss,success_rate\n")
    for r in rows:
        f.write(f'{r["step"]},{r["train_loss"]},{r["final_loss"]},',
                f'{r.get("validation_loss", "")},{r["physics_success_rate"]}\n')
PY
```

拿到输出后，应在结果部分新增一张表，至少填写 first train loss、last train loss、minimum train loss、best validation loss、best step、last-100 mean±SD 和训练期间平均物理成功率。还应使用 k0_training_curve.csv 绘制横轴为 step、纵轴为 Loss 的训练/验证曲线。由于随机 batch Loss 会波动，应同时绘制 25 或 50 step 的滑动平均，不应只用最后一个点判断收敛。

9.2 导出标准和离网格逐点数据

标准评价文件应为

results/gradcell_exploration_linear_constraint/k0_s7/evaluation_spme/candidates.npz，离网格文件通常位于相邻的 unseen/off-grid 评价目录。对两个文件分别运行下面脚本，并把生成的 CSV 作为报告补充数据。

```
python - <<'PY'
import csv
import numpy as np
from pathlib import Path
```

```

jobs = {
    "standard":
Path("results/gradcell_exploration_linear_constraint/k0_s7/evaluation_spme/candida
tes.npz"),
    "offgrid": Path("请替换为离网格评价目录/candidates.npz"),
}
for name, path in jobs.items():
    with np.load(path) as d:
        lam = d["preferences"]
        latent = d["latent"]
        energy = d["energy_wh_kg"]
        r5 = d["energy_retention_5c"]
        r6 = d["energy_retention_6c"]
        loss = d["scalarized_loss"]
        oracle = d["oracle_scalarized_loss"]
        nominal = d["nominal_scalarized_loss"]
    out = Path(f"k0_{name}_points.csv")
    with out.open("w", newline="", encoding="utf-8") as f:
        w = csv.writer(f)
        w.writerow(["lambda", *[f"u{i+1}" for i in range(latent.shape[1])],
                    "energy_wh_kg", "R5", "R6", "worst_R", "loss",
                    "oracle_loss", "regret", "beats_nominal"])
        for i in range(len(lam)):
            w.writerow([lam[i], *latent[i], energy[i], r5[i], r6[i],
                        min(r5[i], r6[i]), loss[i], oracle[i],
                        loss[i]-oracle[i], loss[i] < nominal[i]])]
    print("saved", out)
PY

```

获取两个 CSV 后，应把标准网格的全部 21 行和离网格的全部 20 行附在报告末尾；正文只保留汇总统计和异常点。建议另外绘制 λ -比能量、 λ - R_5/R_6 、 λ -regret 以及五个 u_i - λ 曲线。这样可以直接显示单调性、约束裕量、误差集中区域和 latent 饱和现象。

9.3 计算正式约束下的可行样本数与仿真有效率

下面脚本从参考 NPZ 的元数据读取字段名称，并统计正式 0.50/0.44 阈值下的联合可行数。若数据中保存了 status 字段，也应同时报告每个倍率的有效率；具体 status 字段名称应先用 `print(d.files)` 确认，不能凭空假设。

```

python - <<'PY'
import json
import numpy as np

path = "data/gradcell_reference_spme_1c5c6c_5000_s101.npz"
with np.load(path) as d:
    print("available arrays:", d.files)
    targets = d["targets"]
    metadata = json.loads(str(d["metadata"]))
    fields = metadata["target_fields"]

def col(name):

```

```

return targets[:, fields.index(name)]

specific_e1 = col("specific_energy_1c_wh_kg")
e1 = col("delivered_energy_1c_wh")
e5 = col("delivered_energy_5c_wh")
e6 = col("delivered_energy_6c_wh")
r5 = e5 / np.maximum(e1, 1e-12)
r6 = e6 / np.maximum(e1, 1e-12)
finite = (np.isfinite(specific_e1) & np.isfinite(e1) & np.isfinite(e5)
          & np.isfinite(e6) & (e1 > 0))
feasible = finite & (r5 >= 0.50) & (r6 >= 0.44)
print("total:", len(e1))
print("finite valid:", finite.sum(), "fraction:", finite.mean())
print("joint feasible 0.50/0.44:", feasible.sum(), "fraction:", feasible.mean())
PY

```

如果字段名与示例不同，应以 `metadata["target_fields"]` 打印结果为准替换三处名称。应把 `finite valid` 填入 3.1 节，把 `joint feasible 0.50/0.44` 填入 5.4 节。若有效率明显低于 100%，还需要分别统计失败设计在 latent 空间中的位置，否则参考前沿可能受到求解成功区域的选择偏差影响。

9.4 获取跨种子统计

现有 seed 7 只能说明一次训练成功。建议至少增加模型种子 11、23、42、101，并保持参考数据、前沿、训练步数和 batch size 完全不变。每个种子完成训练后均执行标准与离网格评价，最后报告五次运行的均值、标准差、最小值和最大值。

```

for seed in 7 11 23 42 101; do
  python scripts/run_gradcell_exploration.py \
    --stage train-k0 \
    --reference-samples 5000 \
    --reference-seed 101 \
    --training-steps 1000 \
    --batch-size 8 \
    --preference-points 21 \
    --model-seed "$seed" \
    --output-root results/gradcell_k0_multiseed

  python scripts/run_gradcell_exploration.py \
    --stage evaluate-k0 \
    --reference-samples 5000 \
    --reference-seed 101 \
    --preference-points 21 \
    --model-seed "$seed" \
    --output-root results/gradcell_k0_multiseed
done

```

多种子结果应至少汇总 success rate、constraint satisfaction rate、mean/median/maximum regret、beats-nominal fraction、唯一设计数、能量范围、 R_5/R_6 范围和最大相邻 latent 跳变。如果不同种子的平均 regret 和约束满足率稳定，才能把“K=0 学到了映射”从单次案例提升为可重复结论。

9.5 获取 DFN 外部复核

SPMe 训练后应使用仓库的 `scripts/verify_gradcell_dfn.py` 对均匀抽取的候选点执行 DFN 评价。建议至少包含低倍率端、膝点、高能量端和若干中间点，并报告 DFN 成功率、SPMe-DFN 比能量相对误差、 R_5 与 R_6 相对误差、约束满足率变化以及候选排序相关性。运行参数应先通过以下命令确认：

```
python scripts/verify_gradcell_dfn.py --help
```

完成后，应在报告新增“5.10 DFN 外部复核”，明确区分“SPMe 内部有效”和“DFN 下仍保持有效”。若 DFN 下约束满足率显著下降，则当前 $K=0$ 只能被解释为 SPMc 专用优化器，需要加入模型差异裕量、DFN 微调或多保真训练。

9.6 建立真正的 held-out 偏好测试

当前随机采样器覆盖整个 $[0, 1]$ ，因此任何中点都只能算离网格插值。严格测试需要在训练时主动排除一个连续区间，例如 $[0.40, 0.60]$ ，并把每一步实际采样的 λ 写入日志。训练后只在该区间评价，同时用区间外结果作为对照。建议另外训练一个不排除区间的同种子模型，以量化 held-out 设置造成的性能下降。需要记录的核心结果包括区间内外 mean regret、maximum regret、约束满足率、单调性违反次数、最大 latent 跳变以及与完整训练模型的差值。该实验需要修改训练采样与日志代码，不能仅凭当前 checkpoint 补算。

10. 待填写结果表

以下表格专门保留给服务器原始文件的补充结果。没有运行数据时应保持“待填写”，不能以最后一次终端打印值或人工估计代替。

10.1 训练收敛表

指标	数值
实际完成 step 数	待填写
首个 train Loss	待填写
最后一个 train Loss	待填写
最小 train Loss及 step	待填写
最佳 validation Loss及 step	待填写
最后 validation Loss	待填写
最后 100 step train Loss, mean $\pm$ SD	待填写
训练期物理成功率, mean/min	待填写
实际训练耗时	19654.13 s (已有)

10.2 多随机种子表

model seed	success rate	constraint rate	mean regret	median regret	max regret	beats nominal	unique designs
7	1.0000	1.0000	0.006311	0.001241	待填写	1.0000	21
11	待运行	待运行	待运行	待运行	待运行	待运行	待运行
23	待运行	待运行	待运行	待运行	待运行	待运行	待运行
42	待运行	待运行	待运行	待运行	待运行	待运行	待运行
101	待运行	待运行	待运行	待运行	待运行	待运行	待运行
mean ± SD	待计算	待计算	待计算	待计算	待计算	待计算	待计算

10.3 SPM_e—DFN 复核表

指标	SPM _e	DFN	差异或误差
仿真成功率	1.0000	待运行	待计算
约束满足率	1.0000	待运行	待计算
1C 比能量均值	待导出	待运行	待计算
R_5 均值	待导出	待运行	待计算
R_6 均值	待导出	待运行	待计算
比能量平均相对误差	—	—	待计算
R_5 平均相对误差	—	—	待计算
R_6 平均相对误差	—	—	待计算
候选排序 Spearman 相关系数	—	—	待计算

10.4 严格 held-out 偏好表

测试区域	样本数	mean regret	max regret	constraint rate	单调性违反	最大 latent 跳变
训练区间外对照	待运行	待运行	待运行	待运行	待运行	待运行
held-out [0.40, 0.60]	待运行	待运行	待运行	待运行	待运行	待运行